

Приложение на невронните мрежи в невронно-мускулната активност

1. Въведение

Невронното кодиране представлява процесът, чрез който информацията се представя и предава в нервната система чрез последователности от акционни потенциали. Разбирането на механизмите на генериране и разпространение на тези електрически импулси е от съществено значение за изследването на функционирането на нервната система, както и за разработването на съвременни невроинженерни и биомедицински приложения.

Акционният потенциал е основният механизъм за предаване на информация между невроните и към мускулните клетки. Неговото възникване се определя от сложни взаимодействия между йонни канали и мембранни процеси. За описване на тези процеси са разработени различни математически модели, които се различават по своята сложност и точност.

Един от най-известните модели е моделът на Hodgkin-Huxley, който описва динамиката на мембранный потенциал чрез система от диференциални уравнения и предоставя детайлно представяне на йонните токове. Въпреки високата си биологична достоверност, този модел изисква значителни изчислителни ресурси. Като алтернатива, моделът на Izhikevich предлага по-опростено описание на невронната динамика, като същевременно запазва способността да възпроизвежда разнообразни типове невронна активност.

В настоящото изследване се разглеждат модели за генериране на акционни потенциали с цел анализ на процесите на невронно кодиране. Чрез сравнително изследване на моделите Hodgkin-Huxley и Izhikevich се оценяват техните възможности за описание на невронната активност и приложимостта им при моделиране на кодиращи механизми. Основната цел е да се анализира как различните модели представят характеристиките на акционните потенциали и как могат да бъдат използвани за изследване на процесите на невронно кодиране и предаване на информация.

2. Теоретична постановка

Биологични основи на невро-мускулната активност

Невро-мускулната активност обхваща всички механизми, чрез които нервната система и мозъкът координират и предават сигнали към мускулите, предизвиквайки тяхното съкращаване и отпускане. Това сложно взаимодействие е в основата на всяко движение, включително и в поддържането на стабилна стойка и баланса в тялото. Чрез него нервната система осъществява пряка връзка между мисловните процеси и физическото изпълнение, превръщайки намеренията в действие.

Невро-мускулната система може да бъде разглеждана като йерархична комуникационна структура, в която информацията се предава от централната нервна система към периферните органи чрез електрически и химични сигнали. Въпросните сигнали се генерират, обработват и трансформират в различни части на невронната система, като ключова роля имат невроните и техните връзки.

2.1. Неврони

Невроните, наричани още нервни клетки, са основната структурна и функционална единица на нервната система. Тяхната основна роля е да приемат, обработват и предават информация под формата на електрически и химични сигнали. Чрез тази си функция те изграждат сложна комуникационна мрежа, която позволява бърза и прецизна координация на процесите в организма.

Всеки неврон се състои от няколко основни части - дендрити, клетъчно тяло (сома), аксон и синаптични окончания.

Дендритите представляват разклонени израстъци, които приемат множество входящи сигнали от други неврони и ги насочват към клетъчното тяло.

Клетъчното тяло (сома) съдържа ядрото и органелите, които поддържат жизнените функции на клетката и осъществяват метаболитната ѝ активност. Именно тук се извършва значителна част от обработката на постъпващата информация чрез сумиране на входните възбуждащи и задръжни сигнали.

Аксонът е дълъг израстък, който провежда електрическия импулс от тялото на неврона към други клетки. Той може да бъде обвит в миелинова обвивка, която ускорява провеждането на сигнала чрез т.нар. салтаторно (скачково) провеждане. В края му се намират синаптичните окончания, осъществяващи предаването на генерирания от нервната клетка сигнал към следващата такава посредством химични вещества, наречени невромедиатори.

Специфично за невроните е че се различават по форма, размер и функция в зависимост от своята роля, като особено значение за двигателната система имат моторните неврони, които предават сигнали от централната нервна система към мускулите и така осъществяват волевото движение.

2.2. Клетъчна мембрана и мембранен потенциал

Клетъчната мембрана на неврона представлява тънка полупропусклива структура, която обгръща нервната клетка и отделя вътреклетъчната среда от извънклетъчната. Тя е изградена основно от фосфолипиден двуслой, в който са вградени различни белтъци, холестерол и въглехидратни вериги. Освен защитна функция, тя регулира и обмяна на вещества между клетката и околната среда с помощта на специализирани йонни канали и мембранни помпи.

От двете страни на мембраната имаме неравномерна концентрация на йоните - извън клетката има повече Na^+ и Cl^- , а вътре – повече K^+ и отрицателни белтъци. Това се поддържа основно от натриево-калиевата помпа, която използва енергия, за да изнася Na^+ навън и да внася K^+ навътре.

Движението на йоните през мембраната се определя от два основни фактора - концентрационният градиент, при който йоните се стремят да се придвижват от област с по-висока към област с по-ниска концентрация чрез процеса на дифузия, и електричните сили, породени от разликата в електричния потенциал между вътрешната и външната страна на мембраната.

В резултат на всичко това невронът има отрицателен потенциал (приблизително около -70 mV).

2.3. Акционен потенциал

Акционният потенциал представлява краткотрайна промяна на мембранный потенциал, която възниква при достигане на прагова стойност (threshold) на възбуждане и протича в няколко фази.

Първа е деполяризацията, при която натриеви йони (Na^+) бързо навлизат в клетката през специфични йонни канали, което води до рязко повишаване на мембранный потенциал и може да доведе до потенциално достигане на пик. В случай, че последното се случи, настъпва реполяризация, при която калиеви йони (K^+) излизат от клетката, възстановявайки отрицателния вътрешен потенциал. В някои случаи се наблюдава кратка хиперполяризация, при която потенциалът пада под нивото на покой, след което мембраната се стабилизира.

Този процес е основата на електрическата сигнализация в нервната система и позволява бързо и надеждно предаване на информация, кодирана чрез честотата и времевата последователност на акционните потенциали.

2.4. Синапси и предаване на сигнали

Комуникацията между невроните се осъществява чрез структури, наречени синапси. Когато електрическият импулс достигне края на неврона, в синаптичната цепка се освобождават вещества, наречени невромедиатори. Те преминават към следващата клетка, нарича още “постсинапсна”, и се свързват с рецептори на нейната мембрана, като в зависимост от вида им, те могат да активират или да потиснат следващия неврон.

2.5. Невро-мускулна връзка

Нервно-мускулният синапс е специален вид връзка между моторен неврон и мускулно влакно. Когато акционният потенциал достигне края на моторния неврон, се отделя невромедиатор (най-често ацетилхолин). Той предизвиква промяна в електрическия заряд на мускулната мембрана (деполяризация), което води до съкращаване на мускулното влакно и съответно до движение.

2.5. Невронно кодиране

Невронното кодиране представлява процеса, чрез който информацията в нервната система се представя, предава и обработва посредством последователности от акционни потенциали. Въпреки че отделните акционни потенциали имат сходна форма и амплитуда, информацията се съдържа в тяхната честота, времева организация и разпределение между различни неврони. Благодарение на тези механизми нервната система може да кодира сетивни стимули, двигателни команди и когнитивни процеси.

Една от най-разпространените форми на невронно кодиране е честотното кодиране (Rate Coding). При него информацията се представя чрез честотата на генерираните импулси за определен интервал от време. Колкото по-силен е даден стимул, толкова по-висока е честотата на акционните потенциали. Този механизъм се наблюдава при множество сензорни системи, където интензивността на външния стимул се отразява пряко върху броя генерирани импулси.

Друг важен механизъм е времевото кодиране (Temporal Coding). При него информацията не се определя от броя на импулсите, а от точния момент на тяхното възникване. Дори малки разлики във времето на генериране на спайковете могат да носят значителна информация. Този тип кодиране позволява

много бързо предаване на сигнали и играе важна роля в системи, изискващи висока времева точност, като слуховата и зрителната система.

Третият основен подход е популационното кодиране (Population Coding). При него информацията не се представя от отделен неврон, а от съвместната активност на група неврони. Всеки неврон допринася частично за представянето на даден стимул, като крайната информация се формира от цялата популация. Този механизъм осигурява по-висока надеждност и устойчивост на шум в сравнение с кодирането чрез единични неврони.

В реалната нервна система тези механизми често действат едновременно. Чрез комбинация от честота на импулсите, времева структура и колективна активност на невронни популации мозъкът може ефективно да обработва и предава големи количества информация. Разбирането на принципите на невронното кодиране е от съществено значение както за изучаването на биологичните невронни системи, така и за разработването на съвременни модели на изкуствени и спайкови невронни мрежи.

3. Модели

3.1. Hodgkin-Huxley модел

Моделът на Hodgkin-Huxley, който е вдъхновен от експерименти върху гигантски аксон на сепия, описва процесите, динамиката на мембранный потенциал чрез система от четири диференциални уравнения, базирани на йонните токове през клетъчната мембрана:

$$I = C_m \frac{dV_m}{dt} + \bar{g}_K n^4 (V_m - V_K) + \bar{g}_{Na} m^3 h (V_m - V_{Na}) + \bar{g}_l (V_m - V_l),$$

$$\frac{dn}{dt} = \alpha_n(V_m)(1 - n) - \beta_n(V_m)n$$

$$\frac{dm}{dt} = \alpha_m(V_m)(1 - m) - \beta_m(V_m)m$$

$$\frac{dh}{dt} = \alpha_h(V_m)(1 - h) - \beta_h(V_m)h$$

В уравненията участват следните параметри:

- C_m - мембранен капацитет, обикновено $\sim 1 \mu F/cm^2$;
- V_m - мембрален потенциал;

- $\frac{dV_m}{dt}$ - скорост на изменение на мембранныя потенциал във времето;
- V_K - реверсивен потенциал за калиевите йони;
- V_{Na} - реверсивен потенциал на натриевите йони;
- V_l - реверсивен потенциал на пасивния („leak“) ток;
- m - вероятност натриевите канали да бъдат отворени (активационна променлива);
- h - вероятност натриевите канали да не са инактивирани (инактивационна променлива);
- n - вероятност калиевите канали да бъдат отворени (активационна променлива);
- $\bar{g}_K$ - максимална проводимост на калиевите канали;
- $\bar{g}_{Na}$ - максимална проводимост на натриевите канали;
- $\bar{g}_l$ - проводимост на пасивния ток през мембраната;
- $\alpha_n(V_m)$ - скорост на отваряне на калиевите канали;
- $\beta_n(V_m)$ - скорост на затваряне на калиевите канали;
- $\alpha_h(V_m)$ - скорост на възстановяване на натриевите канали;
- $\beta_h(V_m)$ - скорост на затваряне на натриевите канали;
- $\alpha_m(V_m)$ - скорост на отваряне на натриевите канали;
- $\beta_m(V_m)$ - скорост на затваряне на натриевите канали.

Заради нелинейния характер на уравненията, представени по-горе, в общия случай не съществува аналитично решение на разглежданата задача. Поради тази причина се използва числен подход, при който непрекъснатите функции $V(t)$, $m(t)$, $n(t)$, $h(t)$, описващи състоянието на системата на Hodgkin–Huxley, се заменят с дискретни стойности, така че първоначалната диференциална задача да бъде сведена до алгебрична система.

Векторът на неизвестните се дефинира като:

$u(t) = [V(t), m(t), h(t), n(t)]^T$, където $u(t) : \mathbb{R} \rightarrow \mathbb{R}^4$. Съответно, численото решение ще бъде представено чрез дискретни стойности:

$$y_i = u(t_i) = [V_i, m_i, h_i, n_i]^T.$$

За целта се въвежда понятието “мрежа” (дискретизация на времевата област), която представлява равномерно разбиване на интервала $[t_0, T]$ чрез краен брой точки, наречени “възли” на мрежата.

Мрежата има вида

$\omega_h = \left\{ t_i = t_0 + ih, i = \overline{0, n}, n = \frac{T-t_0}{h} \right\}$. Тук h е стъпката на дискретизация, а n е броят на интервалите.

Във всеки възел t_i се търси приближена стойност на точната функция на решението $u(t)$, т.е. $y_i \approx u(t_i) = u_i$.

По този начин непрекъснатата задача се заменя с дискретна, при която решението се представя чрез последователност от векторни стойности y_i , дефинирани само във възлите на мрежата.

За построяване на числена схема се използва апроксимация на диференциалната задача върху въведената мрежа ω_h . Основната идея е производната да се замени с крайна разлика, което позволява преминаване от диференциален към алгебричен вид на задачата.

Изхождайки от дефиницията на производната, получаваме:

$$u'(t_i) \approx (u(t_{i+1}) - u(t_i))/h.$$

Като се използва, че $y_i \approx u(t_i)$, диференциалната задача се апроксимира чрез:

$$(y_{i+1} - y_i)/h = f(t_i, y_i), i = 0, 1, \dots, n-1.$$


Оттук непосредствено се получава числената схема:

$$y_{i+1} = y_i + hf(t_i, y_i), i = 0, 1, \dots, n-1$$

която представлява явния метод на Ойлер.

Методът се инициализира с началното условие $y_0 = u_0$ и последователно генерира приближени стойности на решението във всички възли на мрежата.

За илюстрация на полученото числено решение на системата на Hodgkin–Huxley е проведена симулация, при която методът на Ойлер е приложен върху зададения времеви интервал. Получените стойности на мембранный потенциал $V(t)$ са визуализирани чрез графика.



От получената графика се наблюдава характерното поведение на мембрания потенциал, включващо фази на деполяризация, пикова стойност и последваща реполяризация, след което системата се стабилизира около равновесно състояние.

3.2. Izhikevich модел

Въпреки че моделът на Hodgkin–Huxley е изключително точен и широко използван, неговата висока изчислителна сложност ограничава приложението му при симулации на големи невронни мрежи. Поради това се използват по-опростени модели, които запазват основните динамични свойства на невронното поведение при значително по-ниска изчислителна цена.

Такъв е моделът на Izhikevich, който съчетава биологична интерпретируемост и ефективност. Той позволява възпроизвеждане на различни типове невронна активност и е особено подходящ за симулации на големи спайкови невронни мрежи (SNN). Моделът се описва чрез система от две диференциални уравнения с две променливи и позволява външният ток да бъде зададен като константа или функция на времето.

$$v' = 0.04v^2 + 5v + 140 - u + I$$

$$u' = a(bv - u)$$

В модела на Izhikevich променливата v представлява мембрания потенциал на неврона, а u е спомагателна променлива, описваща мембранната възстановителна динамика.

Параметърът a определя времевата скала на възстановителната променлива u . По-малки стойности водят до по-бавно възстановяване, като типична стойност е $a=0.02$.

Параметърът b описва чувствителността на u към подпрагови промени в мембрания потенциал v . Типична стойност е $b=0.2$.

Параметърът c задава стойността, към която мембраният потенциал v се връща след спайк, в резултат на бързи K^+ йонни токове. Типично $c=-65$ mV.


Параметърът d описва промяната на възстановителната променлива u след спайк, породена от бавни Na^+ и K^+ токове. Типична стойност е $d=2$.

Специфично за модела на Izhikevich е механизмът за генериране на нервен импулс. Когато мембраният потенциал v достигне зададен праг, се регистрира спайк и се извършва reset: v се задава на c , а u се увеличава с d .

В реализирания от нас модел численото решение се реализира чрез метода на Ойлер за променливите v и u . След всяка итерация се проверява дали v_n е над прага и при условие се прилага reset $v_n \leftarrow c, \quad u_n \leftarrow u_n + d$.

Векторът на състоянието е $[v, u]$, като първата компонента се използва за проверка на спайк състоянието. Така се комбинират методът на Ойлер и дискретният механизъм за генериране на спайкове.

Графика:



3.3. Сравнение на моделите

Моделът на Izhikevich е създаден с цел да запази ключовите характеристики на биологичните неврони, като същевременно намали изчислителната сложност.

Критерий	Hodgkin–Huxley	Izhikevich
Брой уравнения	4 сложни диференциални уравнения	2 прости диференциални уравнения
Изчислителна сложност	Ниска	Висока
Биологична точност	Много висока	Висока
Типове неврони	Универсално (чрез добавяне на нови йонни канали и уравнения)	Голямо разнообразие чрез промяна на параметрите
Основно приложение	Детайлни биофизични изследвания	Големи невронни мрежи и SNN

Въпреки че моделът на Hodgkin–Huxley е по-прецизен от биофизична гледна точка, моделът на Izhikevich предлага значително по-добър баланс между точност и изчислителна ефективност.

3.3.1. Математическа сложност

Една от най-съществените разлики между моделите на Hodgkin–Huxley и Izhikevich е тяхната изчислителна сложност. Тази характеристика е особено важна при симулации на големи невронни мрежи, където броят на невроните може да достига стотици хиляди или дори милиони.

Модел на Hodgkin–Huxley

Моделът на Hodgkin–Huxley използва четири променливи на състоянието – мембранный потенциал V_m и трите gating променливи n, m, h , които описват състоянието на натриевите и калиевите йонни канали. Скоростите на отваряне и затваряне на каналите се определят чрез нелинейни експоненциални функции, което значително увеличава изчислителната сложност.

Поради необходимостта от числено решаване на система от нелинейни диференциални уравнения, всяка времева стъпка изисква голям брой аритметични операции. Това прави модела изключително точен, но сравнително бавен при симулации на големи невронни популации.

Модел на Izhikevich

Моделът на Izhikevich използва само две променливи на състоянието – мембранный потенциал v и възстановяващата променлива u . Уравнението за v съдържа квадратична зависимост, докато уравнението за u е линейно.

Благодарение на тази опростена математическа структура моделът изисква значително по-малко изчислителни ресурси. Въпреки опростяването той успява да възпроизведе широк спектър от биологично наблюдавани режими на невронна активност. Това позволява ефективна симулация на големи невронни мрежи с милиони неврони в разумно време.

3.3.2. Биологична точност

Модел на Hodgkin–Huxley

Моделът описва подробно физическите механизми, които стоят зад генерирането на акционни потенциали.

Той моделира поотделно натриевите (Na^+) и калиевите (K^+) йонни токове и възпроизвежда с висока точност реалните електрофизиологични записи. Поради тази причина моделът често се разглежда като „златен стандарт“ в биофизичното моделиране на неврони.

Модел на Izhikevich

Моделът на Izhikevich не се стреми да описва подробно йонните механизми. Вместо това той пресъздава наблюдаваното поведение на невроните чрез компактна математическа формулировка.

Чрез промяна на четири параметъра моделът може да възпроизведе повече от двадесет различни типа невронна активност, включително всички основни типове кортикални неврони. Макар да не описва детайлно йонните токове, той запазва най-важните времеви характеристики на спайковата активност и е достатъчно точен за моделиране на невронни мрежи на системно ниво.

3.3.3 Практически приложения

Приложения на модела на Hodgkin–Huxley

Моделът се използва основно в изследвания, при които е необходима висока биофизична точност:

- детайлно моделиране на единични неврони;
- изследване на функционирането на йонните канали;
- анализ на генетични мутации, влияещи върху невронната активност;
- фармакологични изследвания на лекарства, въздействащи върху нервната система;
- прецизни електрофизиологични симулации.

Приложения на модела на Izhikevich

Поради високата си ефективност моделът на Izhikevich намира широко приложение в:

- спайкови невронни мрежи (SNN);
- моделиране на големи невронни популации;
- невроморфни изчислителни системи;
- brain-computer interfaces (BCI);
- симулации на мозъчни региони и когнитивни процеси;
- биологично правдоподобни системи за изкуствен интелект.

3.3.4. Компромис между точност и скорост

Изборът между двата модела зависи от конкретната изследователска задача и от наличните изчислителни ресурси.

Въпреки че моделът на Hodgkin–Huxley предоставя най-висока степен на биологична реалистичност, неговата сложност значително ограничава мащаба на възможните симулации. От друга страна, моделът на Izhikevich предлага значително по-добър баланс между биологична достоверност и изчислителна ефективност.

Това го прави особено подходящ в следните случаи:

- когато се симулират големи невронни популации или цели мозъчни региони;

- когато е необходима работа в реално време;
- когато се изследва взаимодействието между различни типове неврони;
- когато изчислителните ресурси са ограничени;
- когато се разработват практически приложения на спайкови невронни мрежи.

Благодарение на този компромис моделът на Izhikevich се е превърнал в един от най-популярните модели в съвременната невроинформатика.

3.3.5. Заключителна оценка

Моделът на Izhikevich може да бъде разглеждан като мост между биологичната реалност и изчислителната ефективност. Той съчетава предимствата на два различни подхода към моделирането на неврони.

Моделът запазва способността да възпроизвежда богат набор от биологично наблюдавани форми на невронна активност, като същевременно неговата проста математическа структура позволява бързи и мащабируеми симулации.

Следователно моделът на Izhikevich:

- съхранява основните биологични характеристики на реалните неврони;
- предлага висока изчислителна ефективност;
- позволява моделиране на голямо разнообразие от невронни типове;
- е подходящ за симулации на мащабни спайкови невронни мрежи;
- представлява оптимален избор за множество съвременни невроинформатични и невроинженерни приложения.

Поради тези причини моделът на Izhikevich е широко използван в изследванията на спайковите невронни мрежи и се счита за един от най-успешните компромиси между биологична правдоподобност и изчислителна ефективност.

4. Анализ на различни типове невронна активност чрез модела на Izhikevich


Една от основните ни задачи по време на провеждането на курса беше използването на модела на Izhikevich за разглеждане и сравнение на поведението на невроните по време на преминаването на електрически импулси чрез тях.

Както е обяснено по-горе, това се осъществява чрез използването на две сравнително прости диференциални уравнения, които съдържат в себе си различни параметри, чиито стойности зависят от вида на разглежданата нервна клетка.


Основните, разглеждани типове са:

1. Regular Spiking (RS) невроните реагира на постоянен входен ток чрез генериране на сравнително равномерна последователност от акционни потенциали. Характерно е, че в началото честотата на импулсите е по-висока,


след което постепенно намалява поради адаптационните процеси. Това поведение наподобява активността на много възбудни кортикални неврони и е важно за моделиране на стабилно предаване на информация. Стойностите на параметрите в модела на Izhikevich са $a = 0.02$, $b = 0.2$, $c = -65 \text{ mV}$ и $d = 2$.




2. *Intrinsically Bursting (IB)* невроните генерират кратки серии от няколко бързи импулса, последвани от период на относителна тишина. Този тип поведение е особено важно за механизми, при които информацията се кодира не само чрез честота, но и чрез структурата на спайковете във времето. Burst-активността позволява по-силно въздействие върху постсинаптичните неврони и често се свързва с процеси на усилване на сигнала и синхронизация в невронни популации. Стойностите на параметрите в модела на Izhikevich са $a = 0.02$, $b = 0.2$, $c = -55 \text{ mV}$ и $d = 4$.




3. При *chattering (CH)* невроните се генерират много бързи и плътни последователности от импулси. Това води до висока честота на спайкове в кратък интервал от време, което е важно за бърза комуникация между невронни групи. Този тип активност често се асоциира с процеси на обработка на информация в зрителната кора и с механизми за синхронизация на невронни ансамбли. Стойностите на параметрите в модела на Izhikevich са $a = 0.02$, $b = 0.2$, $c = -50 \text{ mV}$ и $d = 2$.




4. Fast Spiking (FS) невроните се характеризират със способност за генериране на много висока честота на акционни потенциали без значителна адаптация във времето. За разлика от Regular Spiking невроните, при които честотата постепенно намалява, Fast Spiking невроните поддържат почти постоянна и стабилна честота дори при продължителна стимулация. Подобно поведение е типично за инхибиторните интерневрони в кората на мозъка, особено такива, които използват GABA като невромедиатор, играещи ключова роля в синхронизацията на невронната активност и в контрола върху прекомерното възбуждане в невронните мрежи. Стойностите на параметрите в модела на Izhikevich са $a = 0.1$, $b = 0.2$, $c = -65 \text{ mV}$ и $d = 2$.




5. Thalamocortical (TC) невроните показват по-сложно поведение, което зависи силно от входния сигнал. Те могат да работят както в режим на единични спайкове, така и в burst режим, като по този начин участват в предаването на информация между таламуса и кората. Тяхната динамика е ключова за регулиране на състояния като сън и бодърстване, както и за обработка на сетивни стимули. Стойностите на параметрите в модела на Izhikevich са $a = 0.02$, $b = 0.25$, $c = -65 \text{ mV}$ и $d = 0.05$.



6. Резонаторните (RZ) неврони се характеризират със способност на нервните клетки да реагират по-силно на входни сигнали с определена честота. Това означава, че невронът не само реагира на силата на входа, но и на неговата времева структура. Така се въвежда концепцията за честотна селективност на невроните, която е важна за разбирането на ритмичната активност в мозъка. Стойностите на параметрите в модела на Izhikevich са $a = 0.1$, $b = 0.26$, $c = -65$ mV и $d = 0.05$.



7. При Low-Threshold Spiking (LTS) невроните се активират при сравнително ниски стойности на входния ток. Те могат да генерират акционни потенциали дори при слаба стимулация, което ги прави важни за локални регулаторни функции в невронните мрежи. Този тип поведение често се наблюдава при инхибиторни интерневрони и участва в модулацията на цялостната мрежова активност. Стойностите на параметрите в модела на Izhikevich са $a = 0.02$, $b = 0.25$, $c = -65 \text{ mV}$ и $d = 2$.



Това разнообразие от динамики има ключово значение за спайковите невронни мрежи, разглеждани в следващата точка, тъй като позволява изграждането на модели, които не само предават информация чрез честотата на импулсите, но и чрез тяхната времева структура и групиране.

5. SNN

Спайковите невронни мрежи (Spiking Neural Networks, SNN) са клас невронни модели, вдъхновени от начина, по който биологичните неврони комуникират чрез дискретни импулси (спайкове). За разлика от традиционните невронни мрежи, те работят със събитийно-времеви сигнали вместо с непрекъснати стойности.

Основно понятие при тях е кодировката на информацията, при която числовите данни се преобразуват в спайкови последователности чрез честота или времево разпределение на импулсите.

5.1. Формално представяне на алгоритъма

Алгоритъмът на спайковата невронна мрежа може да бъде представен като последователност от математически операции, които преобразуват входните данни в спайкова активност, обработват я чрез неврони от модела на Izhikevich и накрая декодират получения резултат обратно в числова стойност.

Стъпка 1. Нормализация на входните данни

Входната стойност x се нормализира в интервала $[0, 1]$:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}},$$
 където x_{min} и x_{max} са съответно минималната и максималната стойност в набора от данни.

Стъпка 2. Преобразуване в честота

Нормализираната стойност се преобразува в честота на генериране на спайкове:

$$\alpha = \alpha_{min} + x_{norm}(\alpha_{max} - \alpha_{min}),$$

където:

- α е честотата на спайковете;
- α_{min} е минималната честота;
- α_{max} е максималната честота.

Стъпка 3. Формиране на входен ток

Получената честота α определя интервала между последователните спайкове, а не директно моментите на тяхното възникване. Времеви моменти на спайковете се дефинират чрез равномерно разпределение във времето:

$$t_i = t_0 + \frac{i}{\alpha}, i = 0, 1, 2, \dots$$

Получените спайкове се използват като входни сигнали към невроните в мрежата. В този смисъл всеки спайк се интерпретира като синаптичен импулс, който индуцира временно изменение на входния ток на съответния неврон. Важно е да се отбележи, че става дума за локален вход към отделен неврон (или слой), а не за глобален вход към цялата мрежа.

Входният ток към неврона се моделира като сума от експоненциално затихващи синаптични импулси:

$$I(t) = \sum_i W_i e^{-\frac{t-t_i}{\tau}} H(t - t_i),$$

където:

- W_i са синаптичните тегла;
- t_i са моментите на постъпване на спайковете;
- τ е времеконстантата на затихване;
- $H(t - t_i)$ е Хевисайдова функция, която гарантира, че импулсът влияе само след момента на възникване t_i .

Стъпка 4. Симулация на невронната динамика

Динамиката на всеки неврон се описва чрез модела на Izhikevich:

$$\begin{cases} \frac{dv}{dt} = 0.04v^2 + 5v + 140 - u + I(t) \\ \frac{du}{dt} = a(bv - u) \end{cases}$$

При достигане на праговата стойност: $v \geq 30mV$

се генерира спайк и се изпълнява правилото за reset:

$$\begin{cases} v = c \\ u = u + d \end{cases}$$

Този механизъм реализира невронната активация в спайковата мрежа.

Стъпка 5. Декодиране на резултата

След приключване на симулацията изходната честота се определя чрез броя на генерираните спайкове:

$$\alpha_{output} = \frac{count_{spikes}}{T}$$

където:

- $count_{spikes}$ е броят на изходните спайкове;
- T е времето на симулация.

След това се извършва обратна нормализация:

$$x_{output} = \frac{\alpha_{output} - \alpha_{min}}{\alpha_{max} - \alpha_{min}} (x_{max} - x_{min}) + x_{min}, \text{ където:}$$

- α_{min} е минималната възможна честота на спайковете;
- α_{max} е максималната възможна честота на спайковете;
- x_{max} е максималната стойност в оригиналния входен диапазон;

- x_{min} е минималната стойност в оригиналния входен диапазон.

Получената стойност представлява крайният изход на мрежата.

5.2. Функция на грешката

За обучение на мрежата се използва средна квадратична грешка (Mean Squared Error – MSE):

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

където:

- y_i - истинската стойност за i-тия пример;
- $\hat{y}_i$ - предсказаната стойност от модела за i-тия пример;
- N – брой на обучаващите примери.

Целта на обучението е минимизиране на функцията на грешката L чрез оптимизация на синаптичните тегла W , така че разликата между предсказаните и реалните стойности да бъде минимална.

5.3. Архитектура на мрежата

Схематичното представяне на използваната спайкова невронна мрежа е показано на фигурата по-долу.



Ключова особеност на архитектурата е, че моделът на Izhikevich изпълнява ролята на активационна функция в скрития слой, като преобразува входния ток в спайкова активност.

5.6. Предимства на спайковите невронни мрежи

Спайковите невронни мрежи предлагат редица предимства спрямо традиционните невронни архитектури:

- Енергийна ефективност – изчисления се извършват само при наличие на спайкове.
- Биологична правдоподобност – работата им е близка до тази на реалните неврони.
- Естествена обработка на времеви сигнали – времето е част от самия модел.
- Бърза реакция – подходящи са за приложения в реално време.
- Мащабируемост – позволяват симулация на големи невронни популации.
- Подходящост за невроморфен хардуер – могат ефективно да се реализират върху специализирани изчислителни устройства.

Тези характеристики правят SNN перспективна технология за бъдещи системи за изкуствен интелект, роботика, невроморфни изчисления и brain-computer interfaces.

6. Резултати

Експеримент 1: Сравнение на различни Izhikevich невронни типове при един входен ток

1. Постановка на експеримента

Целта на експеримента е да се анализира поведението на различни типове Izhikevich неврони при еднакъв входен ток и да се изследва как параметрите на модела влияят върху генерирането на спайкове и динамиката на мембрания потенциал.

2. Използвани невронни модели

В експеримента са използвани следните типове Izhikevich неврони:

- RS (Regular Spiking)
- IB (Intrinsic Bursting)
- CH (Chattering)
- FS (Fast Spiking)
- TC (Thalamocortical)
- RZ (Resonator)
- LTS (Low-threshold Spiking)

Всеки неврон се дефинира чрез параметрите a , b , c и d , които определят неговата динамика. Техните стойности са посочени в точка 4 от този доклад.

3. Входен ток

Входният ток е дефиниран: $I(t) = \begin{cases} 10, & 10 < t < 40 \\ 0, & \text{иначе} \end{cases}$

4. Модел на неврона

Всеки неврон се описва по модела на Izhikevich

$$\begin{cases} \frac{dv}{dt} = 0.04v^2 + 5v + 140 - u + I(t) \\ \frac{du}{dt} = a(bv - u) \end{cases},$$


където при достигане на праг $v \geq 30\text{mV}$ се генерира спайк и се прилага reset механизъм



$$\begin{cases} v = c \\ u = u + d \end{cases}.$$



5. Числен метод



Симулацията се извършва чрез метода на Ойлер със стъпка: $\Delta t = 0.01$ за времеви интервал $t \in [0, 100]$.

6. Получени изображения









7. Интерпретация на резултатите

Генерираните по време на експеримента изображения показват, че при подаване на един и същ входен ток различните видове неврони демонстрират качествено различно поведение, което се определя не от големината на постъпващия входен сигнал/ток, а от стойностите на параметрите a , b , c и d .

Regular Spiking (RS) и Fast Spiking (FS) невроните реагират с относително стабилни и предсказуеми спайкови последователности, като FS невроните проявяват по-висока честота на активност. Intrinsic Bursting (IB) и Chattering (CH) невроните генерират характерни групирани импулси (bursting), което отразява тяхната нелинейна вътрешна динамика и склонност към кратки периоди на засилена възбуда. Thalamocortical (TC) и Resonator (RZ) невроните показват по-структурирани и ритмични колебания, което ги прави чувствителни към времеви характеристики на входа. Low-Threshold Spiking (LTS) невроните се активират при по-нисък праг, демонстрирайки висока чувствителност към стимула.

Експеримент 2: Приближаване на функцията x^2 със спайкова невронна мрежа

1. Постановка на експеримента

Целта на експеримента е да се провери способността на реализираната спайкова невронна мрежа, базирана на модела на Izhikevich, да апроксимира нелинейна функция $f(x) = x^2$.

Задачата е формулирана като регресионен проблем, при който входните стойности се кодират чрез спайково представяне, обработват се от невронната мрежа и след това се декодират обратно в числова стойност.

2. Използвана архитектура

Мрежата се състои от един вход, скрит слой от 5 Izhikevich неврона и един изходен слой. Входните данни първо се нормализират и се преобразуват в честота, която определя генерирането на спайкове.

Всеки неврон от скрития слой обработва входния ток чрез динамиката на модела на Izhikevich, като влиянието му се определя от съответното синаптично тегло. Изходът се получава чрез сумиране на невронните активности и последващо декодиране чрез броя на генерираните спайкове.

3. Входни данни

В задачата е използван малък набор от входни стойности:

[3, 4, 8, 10, 25, 24].

Стойностите, които трябва да получим при прилагането на функцията са:

$$y = x^2 = [9, 16, 64, 100, 625, 576].$$

4. Използван модел

Всеки неврон в мрежата се описва чрез системата на Izhikevich

$$\begin{cases} \frac{dv}{dt} = 0.04v^2 + 5v + 140 - u + I(t) \\ \frac{du}{dt} = a(bv - u) \end{cases},$$

където при достигане на праг $v \geq 30mV$ се генерира спайк и се прилага reset механизъм

$$\begin{cases} v = c \\ u = u + d \end{cases}.$$

Параметрите, с които работим са $a = 0.02$, $b = 0.2$, $c = -65 mV$ и $d = 2$.

Самото решаване на задачата се осъществява чрез метода на Ойлер със стъпката dt .

5. Прилагане на алгоритъма от точка 5

Въведените от нас входни данни се нормализират в интервала $[0, 1]$, за да се използват в спайковото кодиране чрез формулата

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}.$$

Полученият нормализиран вектор се използва за спайково кодиране и служи като вход към мрежата: $x_{norm} = [0, 0.0417, 0.2083, 0.2917, 1.0, 0.9583]$.

След това нормализираните стойности се преобразуват в честота на генериране на спайкове, като по-големите стойности съответстват на по-висока честота на импулсна активност: $\alpha = [0, 0.9091, 4.5455, 6.3636, 20, 19.0909] Hz$.

На следващ етап се формира входен ток, моделиран като сума от експоненциално затихващи синаптични импулси с времеконстанта $\tau = 0.5$. Този ток постъпва към невроните от скрития слой и определя тяхната динамика.

Всеки от петте Izhikevich неврона симулира своята динамика независимо чрез числено решаване на системата с метода на Ойлер. Получените времеви сигнали

се сумират, след което чрез детекция на спайкове се изчислява изходната честота на мрежата.

Изходната честота се преобразува чрез обратна нормализация до числова стойност, която представлява крайната предсказана стойност на модела за съответния вход: $y_{pred} = [0.0, 0.0, 0.1, 0.15, 0.6, 0.6]$.

Истинските стойности, нормализирани в същия интервал, са:

$y_{true} = [0.0, 0.01136, 0.08929, 0.14773, 1.0, 0.92045]$.

6. Обучение и оптимизация

За оптимизиране на синаптичните тегла се минимизира функцията на грешката (Mean Squared Error – MSE). Това се извършва чрез числена оптимизация, като е използван методът Nelder–Mead, реализиран чрез `scipy.optimize.minimize`. Методът не използва градиенти, а търси оптимални стойности на теглата чрез итеративно сравнение на стойностите на функцията на грешката.

7. Отклонение и грешка

x	y_true	y_pred	error
3	0	0	0
4	0.0114	0	0.0114
8	0.0893	0.1000	0.0107
10	0.1477	0.1500	0.0023
25	1.0000	0.6000	0.4000
24	0.9205	0.6000	0.3205

Средната квадратична грешка (MSE), използвана като функция на загуба при обучението, е приблизително: $MSE \approx 0.0438$.

8. Заключение

Експериментът показва, че спайковата невронна мрежа, базирана на модела на Izhikevich, може да апроксимира функцията x^2 , като улавя основната ѝ тенденция. Най-добри резултати се получават в средния

диапазон на стойностите, докато при по-високи входове се наблюдават по-големи отклонения.

Това се дължи на опростеното спайково кодиране и агрегиране на изхода. Въпреки това, резултатите потвърждават, че моделът е приложим за нелинейна апроксимация, макар и с ограничена точност.

7. Заключение

В настоящия доклад бяха разгледани биологичните основи на невронната и невро-мускулната активност, както и основните механизми за предаване и кодиране на информация в нервната система. Представени бяха моделите на Hodgkin-Huxley и Izhikevich, които позволяват математическо описание и симулация на невронната динамика, както и прякото им приложение за симулиране на невронната активност.

Разгледани бяха също спайковите невронни мрежи (SNN), които използват принципи, близки до тези на биологичните неврони, и предоставят ефективен подход за моделиране на невронното кодиране. Чрез практическата реализация беше демонстрирано приложението на тези модели при обработка и представяне на информация.

Получените резултати показват, че невронните мрежи и по-специално SNN представляват перспективен инструмент за изследване на невро-мускулната активност и намират приложение в области като невроинженерството, медицината и изкуствения интелект.

8. Източници

[1] Wikipedia, “Неврон,”

<https://bg.wikipedia.org/wiki/Неврон>

[2] Wikipedia, “Hodgkin–Huxley model,”

https://en.wikipedia.org/wiki/Hodgkin%E2%80%93Huxley_model

[3] A. L. Hodgkin and A. F. Huxley, “A quantitative description of membrane current and its application to conduction and excitation in nerve,” *The Journal of Physiology*, vol. 117, pp. 500–544, 1952, doi: 10.1113/jphysiol.1952.sp004764.

[4] E. M. Izhikevich, “Simple model of spiking neurons,” *IEEE Transactions on Neural Networks*, 2003.

Available: <https://www.izhikevich.org/publications/spikes.pdf>

[5] E. M. Izhikevich, “Which model to use for cortical spiking neurons,” 2004.

Available: <https://www.izhikevich.org/publications/whichmod.pdf>

[6] W. Gerstner, W. Kistler, R. Naud, and L. Paninski, *Neuronal Dynamics: From Single Neurons to Networks and Models of Cognition*. Cambridge, UK: Cambridge University Press, 2014.

[7] R. Siciliano, “The Hodgkin-Huxley Model: Its Extensions, Analysis and Numerics,” 2012.

Available:

https://learn.fmi.uni-sofia.bg/pluginfile.php/594917/mod_resource/content/1/RyanSicilianoHH.pdf

[8] A. Scott, *Neuroscience: A Mathematical Primer*.

Available:

https://www.nice-math.com/_files/ugd/bfd2e9_6c4587403561418c9d5073eb61029069.pdf